

加权图拉普拉斯算子

Agent 通过 N 个节点连通加权简单无向图通信

$$G = (V, E) \quad V = [1, 2, \dots, N] \quad E \subseteq U \times V \quad V \Rightarrow \text{节点} \quad E \Rightarrow \text{边}$$


$$\forall i \in V, (i, i) \notin E$$

该图是连通的 $\Rightarrow$ 所有的 w_{ij} 不为零 遍历可达 ! 可存在 0

加权邻接矩阵 (标志有无连接 & 权重大小)

$$A(G)_{ij} = \begin{cases} w_{ij} & (i, j) \in E \\ 0 & \end{cases} \Rightarrow \text{对角线上的元素为0, 且是对角线对称}$$

度矩阵 (每一列的权重之和) $\Rightarrow$ 所有与节点相连边权重之和

$$d_i = \sum_j w_{ij}$$


加权度

Weighted Graph Laplacian

$$L = D - A(G)$$

对角 $\Rightarrow$ 总连接强度

非 $\sim \Rightarrow$ 耦合度

在拉 ~ 矩阵中有两个特征值是要注意

关于特征值

矩阵 A 相当于将 v (特征向量) 进行变换的方式, 特征值即为缩放倍数

即

$$A\vec{v} = \lambda\vec{v}$$

$\therefore$ 方程有非 0 解 $\Rightarrow (A - \lambda I)$ 矩阵不可逆 $\Rightarrow ?$

$\det(A - \lambda I) = 0$ 单位矩阵 $\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$ 对角线为1, 其余为0

解 $A - \lambda I$ 这个矩阵就能得出特征值,

对于拉~矩阵

$$0 = \lambda_1 \leq \lambda_2 \leq \lambda_3 \dots \leq \lambda_N$$

$\lambda_1 \Rightarrow$ 矩阵对称且行和为0

$\lambda_2 \Rightarrow$ (代数连通度) 衡量图切分为两半的难度

$\lambda_1 \begin{cases} > 0 : \text{图是连通的, 不存在孤岛} \\ = 0 : \text{至少有两个部分是分开的} \end{cases}$

$\Rightarrow$ 定义1

λ_1 大小体现了连接的紧密程度 $\longrightarrow$ 1. 进入编队速度 (收敛速度)

2. 稳定性

设计中心节点?

$\hookrightarrow$ 不可以

差分隐私 $\Rightarrow$ 轨迹保护

定义3 (限定灵敏度) $\Rightarrow$ 隐私保护强度

$\hookrightarrow$ 时间步

若两长度为H的状态轨迹 x & x' 满足

$$\|x - x'\|_{L_1} \leq b_i \rightarrow \text{设定的最大上限}$$

$\hookrightarrow$ 欧氏距离 (偏移量)

$$x = [x(1), x(2), \dots, x(H)]$$

$$x' = [x'(1), x'(2), \dots, x'(H)]$$

$$\|x - x'\|_1 = \sqrt{\sum_{k=1}^H \|x(k) - x'(k)\|^2}$$

$\hookrightarrow$ 将这H个时刻里 x 和 x' 间每一个瞬间的差值的总欧氏距离

文中将 $H \Rightarrow \infty$, 非收敛, 但在实际中为避免超出误差范围, 会限制时间窗口 H

因此, 公式应当为

$$\|z\|_{L_1} = \left(\sum_{k=1}^{\infty} \|z(k)\|_1 \right)^{\frac{1}{L_1}}$$

最终定义 (分类器, 确定需要遮掩的范围)

$$\text{Adj}_{b_i}(v_i, r_i) = \begin{cases} 1 & \|v_i - r_i\|_{L_1} \leq b_i \\ 0 & \text{else} \end{cases}$$

↓
判断是否
相邻

定义 4 (差分隐私) & 高斯机制

定义 4: 差分隐私标准

$\epsilon_i > 0$ & $\delta_i \in (0, 0.5)$ 为隐私参数

$b_i > 0$

$$P[M(x_i) \in S] \leq e^{\epsilon_i} P[M(x'_i) \in S] + \delta_i$$

ϵ_i 通常取 $[0.1, 1/n^2]$ δ_i 在 $[0, 0.05]$ 之间

ϵ & δ 到底是什么?

$\epsilon \Rightarrow$ (隐私预算)

$\delta \Rightarrow$ (容错率)

ϵ 越小, 隐私越高, 迷雾越浓

在极少数情况下会露馅

高斯机制 (Lemma 1) 具体加噪方法

$$\tilde{x}_i = x_i(k) + v_i(k) \Rightarrow \text{噪声}$$


↳ 原始数据

$v_i(k)$ 服从 $N(0, \sigma_i^2 Id)$, 其标准差满足

$$\delta_i \geq \frac{b_i}{2\varepsilon_i} (k_{\delta_i} + \sqrt{k_{\delta_i}^2 + 2\varepsilon_i}) \Rightarrow \delta_i \propto \frac{b_i}{\varepsilon_i}$$

($k_{\delta_i} = Q^{-1}(\delta_i)$) 为 Q 函数 (标准正态分布的右尾概率) 的反函数

右尾 $\Rightarrow$



$Q^{-1} \Rightarrow$ 概率 $\Rightarrow$ 数值

$Q \Rightarrow$ 数值 $\Rightarrow$ 概率