

## 加权图拉普拉斯算子

Agent 通过  $N$  个节点连通加权简单无向图通信

$$G = (V, E) \quad V = [1, 2, \dots, N] \quad E \subseteq U \times V \quad V \Rightarrow \text{节点} \quad E \Rightarrow \text{边}$$


$$\forall i \in V, (i, i) \notin E$$

该图是连通的  $\Rightarrow$  所有的  $w_{ij}$  不为零 遍历可达 ! 可存在 0

加权邻接矩阵 (标志有无连接 & 权重大小)

$$A(G)_{ij} = \begin{cases} w_{ij} & (i, j) \in E \\ 0 & \end{cases} \Rightarrow \text{对角线上的元素为0, 且是对角线对称}$$

度矩阵 (每一列的权重之和)  $\Rightarrow$  所有与节点相连边权重之和

$$d_i = \sum_j w_{ij}$$


加权度

## Weighted Graph Laplacian

$$L = D - A(G)$$

对角  $\Rightarrow$  总连接强度

非  $\sim \Rightarrow$  耦合度

在拉 ~ 矩阵中有两个特征值是要注意

## 关于特征值

矩阵  $A$  相当于将  $v$  (特征向量) 进行变换的方式, 特征值即为缩放倍数

即

$$A\vec{v} = \lambda\vec{v}$$

$\therefore$  方程有非 0 解  $\Rightarrow (A - \lambda I)$  矩阵不可逆  $\Rightarrow ?$

$\det(A - \lambda I) = 0$  单位矩阵  $\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$  对角线为1, 其余为0

解  $A - \lambda I$  这个矩阵就能得出特征值,

对于拉~矩阵

$$0 = \lambda_1 \leq \lambda_2 \leq \lambda_3 \dots \leq \lambda_N$$

$\lambda_1 \Rightarrow$  矩阵对称且行和为0

$\lambda_2 \Rightarrow$  (代数连通度) 衡量图切分为两半的难度

$\lambda_1 \begin{cases} > 0: \text{图是连通的, 不存在孤岛} \\ = 0: \text{至少有两个部分是分开的} \end{cases}$

$\Rightarrow$  定义1

$\lambda_1$  大小体现了连接的紧密程度  $\longrightarrow$  1. 进入编队速度 (收敛速度)

2. 稳定性

设计中心节点?

$\hookrightarrow$  不可以

差分隐私  $\Rightarrow$  轨迹保护

定义3 (限定灵敏度)  $\Rightarrow$  隐私保护强度

$\hookrightarrow$  时间步

若两长度为  $H$  的状态轨迹  $x$  &  $x'$  满足

$$\|x - x'\|_{L_1} \leq b_i \rightarrow \text{设定的最大上限}$$

$\hookrightarrow$  欧氏距离 (偏移量)

$$x = [x(1), x(2), \dots, x(H)]$$

$$x' = [x'(1), x'(2), \dots, x'(H)]$$

$$\|x - x'\|_1 = \sqrt{\sum_{k=1}^H \|x(k) - x'(k)\|^2}$$

$\hookrightarrow$  将这  $H$  个时刻里  $x$  和  $x'$  间每一个瞬间的差值的总欧氏距离

文中将  $H \Rightarrow \infty$ , 非收敛, 但在实际中为避免超出误差范围, 会限制时间窗口  $H$

因此, 公式应当为

$$\|z\|_{L_1} = \left( \sum_{k=1}^{\infty} \|z(k)\|_1^2 \right)^{\frac{1}{2}}$$

最终定义 (分类器, 确定需要遮掩的范围)

$$\text{Adj}_{b_i}(v_i, r_i) = \begin{cases} 1 & \|v_i - r_i\|_{L_1} \leq b_i \\ 0 & \text{else} \end{cases}$$

↓  
判断是否  
相邻

定义 4 (差分隐私) & 高斯机制

定义 4: 差分隐私标准

$\epsilon_i > 0$  &  $\delta_i \in (0, 0.5)$  为隐私参数

$b_i > 0$

$$P[M(x_i) \in S] \leq e^{\epsilon_i} P[M(x'_i) \in S] + \delta_i$$

$\epsilon_i$  通常取  $[0.1, 1/n^2]$   $\delta_i$  在  $[0, 0.05]$  之间

$\epsilon$  &  $\delta$  到底是什么?

$\epsilon \Rightarrow$  (隐私预算)

$\delta \Rightarrow$  (容错率)

$\epsilon$  越小, 隐私越高, 迷雾越浓

在极少数情况下会露馅

高斯机制 (Lemma 1) 具体加噪方法

$$\tilde{x}_i = x_i(k) + v_i(k) \Rightarrow \text{噪声}$$


↳ 原始数据

$v_i(k)$  服从  $N(0, \sigma_i^2 Id)$ , 其标准差满足

$$\delta_i \geq \frac{b_i}{2\epsilon_i} (k\delta_i + \sqrt{k\delta_i + 2\epsilon_i}) \Rightarrow \delta_i \propto \frac{b_i}{\epsilon_i}$$

( $k\delta_i = Q^{-1}(\delta_i)$ ) 为 Q 函数 (标准正态分布的右尾概率) 的反函数

右尾  $\Rightarrow$



$Q^{-1} \Rightarrow$  概率  $\Rightarrow$  数值

$Q \Rightarrow$  数值  $\Rightarrow$  概率

`numpy.random.normal(0, sigma)`

这一步是这样加噪的

$$v_{ik} \sim \mathcal{N}(0, \delta_i I_d)$$

$\downarrow$  高斯分布       $\downarrow$  上面算出来的

$\nearrow$  独立同分布  
 这一秒 & 下一秒无关!

集群羊控制方程

$$\tilde{x}_i[k+1] = \tilde{x}_i[k] + \gamma \sum_{j \in N_i} w_{ij} (\tilde{x}_j[k] - \tilde{x}_i[k] - \underbrace{\Delta_{i,j}}_{\text{自然噪声}}) + \underbrace{n_i[k]}_{\text{人工标定, 用来组队}}$$

算法 1 (Algorithm 1)

Agent 工作流

**Algorithm 1:** Private formation controller (Solution to Problem 1.1)

**Inputs:**  $\epsilon_i > 0$ ,  $\delta_i \in (0, 1/2)$ ,  $b_i > 0$  for all  $i \in [N]$ ,  $\Delta_{ij}$  for all  $(i, j) \in E$

**Outputs:** Privately assembled formation

**for**  $k = 1, 2, \dots$  **do**

**for**  $i \in [N]$  **do**

        Agent  $i$  sends  $\tilde{x}_i(k)$  to agents  $j \in N_i$   $\rightarrow$  发送

        Agent  $i$  receives  $\tilde{x}_j(k)$  for all  $j \in N_i$   $\rightarrow$  接收

        Agent  $i$  executes the state update in (4)  $\rightarrow$  公式 4

引理 2 (Lemma 2)  $\Rightarrow$  标定了混乱是如何传递的

$$\bar{x}[k+1] = (I - \gamma L) \bar{x}[k] + \underbrace{z[k]}_{\text{总噪声}} \Rightarrow \left. \begin{array}{l} \text{固有噪声} \\ \text{隐私噪声} \end{array} \right\}$$

$\downarrow$   
 网络的自愈能力指数

偏差向量

$$(I - \gamma L(G))$$

$\downarrow$   
 学习率

#### 4.3 稳态误差极限 (Theorem 2)

$$e_{cs} \leq \frac{\gamma d \sum_{i=1}^N C w_i G_i^4 + \frac{N-1}{N\gamma} \sum_{i=1}^N s_i^2}{N \lambda_1(L(G)) (2 - \gamma \lambda_1(L(G)))} \Rightarrow \text{自然自带}$$

↑ 隐私代价

$$C w_i d_i = \sum_{j=1}^N w_{i,j} - \frac{d_i^2}{N}$$

隐私 & 网络的共同调优

Problem 强隐私  $\rightarrow$  高方差数据产生网络污染

① 搜索空间

1) 硬件决定了连接的链路

## 2) 可选的一些参数

① 隐私参数最大值  $\epsilon_i = e^i$  (不能超过下发最大值)

② 隐私优化  $\Rightarrow$  算法让  $\epsilon_i$  越小越好

在计算机上具体实现 & 双凸优化

$e_r$   $\epsilon_i^{\max}$   $B$ (网络边预算)  $\Rightarrow$  最小化  $\sum \epsilon_i^2 - y$  (连通度)

引入辅助变量  $y$

1. 噪声项  $< y(2 - ry)$

2.  $y \leq \lambda_1(L)$

交替凸搜索

1. 固定  $\epsilon$ , 优化  $w$  &  $y$

2. 固定  $w$ , 优化  $\epsilon$