

基于前缀树的差分隐私研究论文笔记

相关的模型及解释

查询概率模型

1. 随机查询，每个位置在每次被查询的概率相等
 2. 查询是有放回的（即轨迹不会成环）
 3. 由(1)，查询之间没有相关性，可以视为独立事件
- 根据假设 1，查询中的第一个位置有 $|\mathcal{L}|$ 种可能性
 - 剩余查询中的每个位置将有 $|\mathcal{L}| - 1$ 种可能性
 - $N_l = |\mathcal{L}| * (|\mathcal{L}| - 1) * (|\mathcal{L}| - 1) * \dots * (|\mathcal{L}| - 1) = |\mathcal{L}| * (|\mathcal{L}| - 1)^{l-1}$ (2)
 - 对于长度为L的轨迹，其查询总数的方程为下面的方程
 - $N = \sum_{l=l_{min}}^{l_{max}} N_l = \frac{|\mathcal{L}| * (|\mathcal{L}| - 1)^{l_{min}-1} [(|\mathcal{L}| - 1)^{l_{max}-l_{min}+1} - 1]}{|\mathcal{L}| - 2}$ (3)
 - 接下来是自底向上推断查询的概率
 - 首先检查与叶节点相关的轨迹，即长度最长的轨迹 $l = l_{max}$
 - 故叶节点的查询概率可以用下面的公式表示
 - $p_{leaf} = \frac{1}{N} = \frac{|\mathcal{L}| - 2}{|\mathcal{L}| * (|\mathcal{L}| - 1)^{l_{min}-1} [(|\mathcal{L}| - 1)^{l_{max}-l_{min}+1} - 1]}$ (4)
 - 往上一层之后，父节点的概率是其本身加上所有子节点之和，即下面的公式
 - $p_i = p_{itself} + k * p_{child} = 1/N + k/N$ (5)
 - 故所有节点的查询概率可以以下面的公式表示
 - $p_i = p_{itself} + \sum_{j \in child(i)} p_j = 1/N + \sum_{j \in child(i)} p_j$ (6)
 - 解释：
这是整个模型的基础。一个父节点被“查询”到，意味着它的孩子节点也被“查询”到了，因为父节点是孩子节点的“前缀”。所以父节点的总查询概率就是“自身直接被命中”的概率加上所有孩子被命中的概率之和

最优隐私预算分配算法（拉格朗日松弛法）

设 X 服从拉普拉斯分布， $X \sim Laplace(\mu, b)$ ，则 X 的概率密度函数为：

- $f(x|\mu, b) = \frac{1}{2b} e^{-\frac{|x-\mu|}{b}}$ (7)

由于该节点被查询的概率为 p_i ，所以添加噪声后的总查询误差期望可以表示为下列公式，要让公式 (9) 最小化

- $minimize f(\epsilon_i) = \sum_i E(Err(i))/2 = \sum_i p_i / \epsilon_i^2$ (8)

- $\sum_{i \in path(root, j)} \epsilon_i = \epsilon \quad \forall j \in leaf$ (9)

故每一条线的路径的总预算都为 ϵ

- $\epsilon_G + \epsilon_B + \epsilon_A = \epsilon$
- $\epsilon_N + \epsilon_H + \epsilon_C + \epsilon_A = \epsilon$
- ...
- $\epsilon_M + \epsilon_F + \epsilon_A = \epsilon$ (10)

这里的目标是**最小化所有节点的查询误差总和**。

每个节点的误差贡献由两部分组成： p_i （被查询的频率，权重）和 $1/\epsilon_i^2$ （添加噪声导致的方差项，即隐私带来的代价）。

这是一个经典的凸优化问题：如何在满足线性约束（预算和为 ϵ ）的前提下，调整 ϵ_i 使得 $\sum p_i/\epsilon_i^2$ 最小。

- 所有的约束条件：
 - $minimize \quad f(\epsilon_i) = \sum_i \frac{p_i}{\epsilon_i^2}$
 - $s.t. \quad \sum_{i \in path(root, j)} \epsilon_i = \epsilon \quad \forall j \in leaf$
 - $p_i = \frac{1}{N} + \sum_{j \in child(i)} p_j$
 - $p_{leaf} = \frac{|\mathcal{L}|-2}{|\mathcal{L}| * (|\mathcal{L}|-1)^{l_{min}-1} [(|\mathcal{L}|-1)^{l_{max}-l_{min}+1}-1]}$ (11)

此处省略了一大堆的计算推导过程...

在最后可以推出下列式子

- 对于叶节点
 - $\frac{dL(\epsilon_i)}{d\epsilon_i} = -2 * \frac{p_i}{\epsilon_i^3} + \lambda_i = 0$ (13)
- 对于非叶节点
 - $\frac{p_i}{\epsilon_i^3} = \sum_{a \in [1, k]} \frac{1}{2} \lambda_a = \sum_{a \in [1, k]} \frac{p_{childleaf_{ia}}}{\epsilon_{childleaf_{ia}}^3}$ (23)

此处给出一些解释

拉格朗日松弛法的应用 (Eq. 12):

- 原始问题是“带有路径约束的最小化”，这很难直接求导。
- 通过引入**拉格朗日乘子** λ ，将约束条件 $\sum \epsilon = \epsilon$ “惩罚”项加入目标函数中，转换成了无约束优化问题。这使得我们可以利用微积分（对 ϵ_i 求偏导）来寻找最小值点。

导数意义 (Eq. 13 & 15):

- 令导数等于 0 是寻找函数极值点的标准步骤。
- 这里的直观含义是：在最优预算分配下，每个节点的“边际效用”（对减少误差的贡献）与它的隐私成本（由 λ 反映的某种 Lagrange 乘子平衡）达到了均衡。

命题 1-3 的意义:

- 这些命题简化了计算复杂度。例如，命题 2 指出兄弟叶节点必须平分预算，命题 3 给出了非叶节点与其所有后代叶节点之间预算的递推关系。
- 这意味着我们不需要同时解成百上千个复杂的方程组，而是可以根据这些性质，通过自顶向下或自底向上的递归算法来高效求解最优解。这正是该模型实现“高效”的关键所在。

相关的公式及解释

相对误差数学公式

$$relative_error = |q(\hat{D}) - q(D)| / \max(q(D), s)$$

用途：是用来定量测量所开发算法对轨迹数据集的影响

具体可以看fig3-7的内容，被用来和其他几个基线算法做比较

解释：

- q 是一个计数查询函数，返回轨迹数据集中子轨迹的数量
- $q(D)$ 是原始数据集 D 的计数查询结果
- $q(\hat{D})$ 代表脱敏数据集 $\hat{D}$ 的计数查询结果
- 方程中的 s 代表理性界 (sanity bound)
- 通常在许多差分隐私研究中被设为数据集的 0.1% (为了防止epsilon过小击穿下限，让误差起飞)

主要具体的程序运行过程（伪代码）

算法 1 主函数

输入：原始交通轨迹 D

输入：前缀树高度 h

输入：可用的总隐私预算 ϵ

输入：阈值参数 k, b

输出：脱敏轨迹数据集 $\hat{D}$

1. 扫描一次 D 以构建 PT 并用树结构存储 D ;
2. $PT \leftarrow BudgetAllocation(PT, \epsilon)$
3. 从树层级 $lv = 1$ 的根节点开始;
4. 当 $lv \leq h$ 时:
5. 计算层级 lv 的隐私阈值, $\theta_{lv} = k \times (lv)^{-1} + b$;
6. 对于 PT 中层级 lv 的每个节点 i :
7. $i.count + = Lap(1/\epsilon_i)$
8. $BuildChildTree(i, \epsilon_i, c_i, \theta_{lv})$;
9. 结束循环
10. $lv + +$;
11. 结束循环
12. $\hat{D} \leftarrow Output(PT)$; 返回 $\hat{D}$ 。

过程 1 BudgetAllocation

输入：前缀树根节点 PT ，总预算 ϵ

输出：具有优化预算 ϵ_i 的脱敏前缀树 PT'

1. 函数 Allocate (i)
2. 如果 i 是叶节点，则
3. $\epsilon_i = \epsilon$
4. 跳出
5. 否则
6. 对于 i 的每个子节点 j ，执行
7. Allocate (j)
8. 结束循环
9. $sum = 0$
10. 对于从节点 i 衍生的每个叶节点 $leaf_i$ ，执行
11. $sum += \epsilon / \epsilon_{leaf_i}^3$
12. 结束循环
13. $\epsilon_i = i. (children_{count} / sum^{\frac{1}{3}})$
14. Normalize ($i, \epsilon_i / \epsilon + 1$)
15. 结束循环
16. 结束函数
17. 函数 Normalize ($i, coef$)
18. $\epsilon_i \neq coef$
19. 如果 i 不是叶节点，则：
20. 对于 i 的每个子节点 j ，执行
21. Normalize ($j, coef$)
22. 结束循环
23. 结束判断
24. 结束函数
25. 从 PT 的根节点开始预算分配：Allocate (root)

过程 2 BuildChildTree

输入：父节点 i ，位置 l_i ，时间 t_i ；阈值 θ_{lv} ，隐私预算 ϵ_i ，带噪计数 c_i ；可达位置矩阵 RL

输出：带噪子节点集 $\mathcal{N}$

1. $sum = 0$;
2. 对于 i 的每个子节点 j ，执行
3. $c_j += \text{Lap}(1/\epsilon_i)$;
4. 如果 $c_j \geq \theta_{lv}$ 那么

5. $\mathcal{N} \leftarrow j$;
6. $sum+ = c_j$;
7. 结束判断
8. 如果 $sum \geq c_i$ 那么
9. 跳出循环;
10. 结束判断
11. 结束循环
12. 当 $sum < c_i$ 时
13. 随机选择一个时间 $t_j \in T$, 且 $t_j > t_i$
14. 在时间 $(t_j - t_i)$ 内查找从 l_i 出发的可达位置集 $\mathcal{L}_r$
15. 对于每个位置 $l_j \in \mathcal{L}_r$ 执行
16. $count = \text{Lap}(1/\epsilon_i) + 0$
17. 如果 $count \geq \theta_{lv}$ 那么
18. 添加 $e_{out} = t_j l_j$ 作为新的外向边;
19. 添加节点 j 作为新的子节点;
20. $c_j = count$;
21. $sum+ = count$;
22. 结束判断
23. 如果 $sum \geq c_i$ 那么
24. 跳出循环;
25. 结束判断
26. 结束循环
27. 结束循环
28. 返回 $\mathcal{N}$;

解释: **BuildChildTree** 的逻辑 (Procedure 2):

- 这段代码描述了如何“生长”出一棵带噪声的树。它通过不断添加拉普拉斯噪声 ($\text{Lap}(1/\epsilon_i)$) 来模糊真实的乘客流量信息, 只有当计数值超过阈值 θ_{lv} 时, 节点才会被保留。这有效过滤了由噪声引起的小概率错误路径。

可达位置矩阵 (Reachable location matrix RL):

- 这是一个交通领域特有的约束。它不是纯粹的数据处理, 而是结合了地理和时间限制 (即在时间 $t_j - t_i$ 内, 从 l_i 到 l_j 是否真的可行)。这能确保脱敏后的轨迹仍然是“交通逻辑合理”的, 从而极大地提升了数据的可用性。

隐私保证的闭环:

- 论文最后再次强调了差分隐私的**组合性质**:
 - **并行组合**: 同一层级的节点不重叠, 互不影响隐私预算。

- 序列组合：同一条路径上的节点是串联的，因此必须满足“和 $\leq \epsilon$ ”。这是证明该算法严格满足 ϵ -差分隐私的逻辑基石。

1. 运行时间拆解 (Runtime Breakdown):

- 论文通过实验证明了算法在处理 2.2 亿条记录的大规模数据集时非常快 ($<100s$)。
- 耗时瓶颈：实验明确指出 75% 的时间消耗在“数据脱敏”（即添加拉普拉斯噪声和构建带噪前缀树）上。这符合差分隐私算法的预期，因为噪声生成和树遍历是核心计算开销。

2. 参数校准的必要性:

- 参数 k 和 b 决定了过滤阈值 θ_{lv} 。论文提醒读者，这两个参数并不是越大越好，存在一个最优平衡点。这对于实际应用中的算法调优非常重要。

3. 理性界 (Sanity Bound) 的标准性:

- 论文解释了为何选择 0.1% 作为理性界，因为这是差分隐私领域的“通用惯例”，这增加了论文结果在科学界的可信度和可比性。

全文总结

这篇论文的核心贡献可以概括为以下四个层面：

从“经验”到“严谨”的范式转变：论文摒弃了以往 DP 算法在树结构上简单平均分配预算的经验做法，首次从数学优化角度审视该问题。

创新的数学建模：

- 查询概率模型：**巧妙地利用组合数学推导出轨迹节点被查询的概率，考虑到交通数据的物理约束（如无循环路径）。
- 拉格朗日优化框架：**这是论文的灵魂，通过拉格朗日乘子法，在复杂的路径约束下找到了 ϵ_i 的全局最优分配解。

理论指导下的高效算法：提出的三个核心命题（关于兄弟节点、父子节点预算的数学关系）不仅证明了方案的合理性，还简化了算法复杂度，使得大规模轨迹数据（深圳地铁 2.8 亿记录）能在 160 秒内完成处理。

实际应用的验证：实验结果不仅表明了该方法在数据效用（准确性）上优于 SeqPT 等主流基准算法，还通过灵敏度分析证明了算法在不同参数下的鲁棒性。